Final practice exam (25%)

*** การทดสอบข้อนี้ให้ใช้โมเดลสร้างจากเริ่ม (Built from scratch) โดยใช้ NumPy, Pandas, และ/หรือ Matplotlib เท่านั้น**

1. **เรื่อง: การวิเคราะห์การถดถอยเชิงเส้น (Regression analysis)**

   นักวิเคราะห์ต้องการสร้างโมเดลคำนวณเชิงเลขเพื่อสร้างราคาประเมินห้องชุดสำหรับขาย (Sell price) จากคลังข้อมูลอสังหาริมทรัพย์ในองค์กรตามตารางที่ 1 ประกอบด้วยข้อมูลพื้นที่ขนาดที่ใช้สอยในห้อง (Size of usable area) ข้อมูลราคาประเมินจากกรมที่ดิน (Estimated Price by Dept. of Lands) และจำนวนห้องใช้สอยย่อย (Number of sub-rooms) **(คะแนน 10%)**

   <u>จงหา</u>

   1.) นักวิเคราะห์ท่านนี้ควรใช้ตัวแปรต้นใดที่สร้างความสัมพันธ์ระหว่างตัวแปรตามเชิงทำนายต่อตัวแปรตามจริงได้สัมพันธ์ที่สุดอ้างอิงจากการประเมินค่าความผันแปรของตัวแปรตอบสนองที่สามารถอธิบายได้ (R-square) **(คะแนน 8%)**

   2.) จากโมเดลข้อ 1.1 ให้ประเมินราคาขายห้องของลูกค้าท่านหนึ่งที่ป้อนเข้ามาว่าต้องการขายห้องชุดของตนที่มีขนาด 125 ตารางเมตร ราคาประเมินจากกรมที่ดิน 1,300,000 บาท และมีห้องย่อย 3 ห้อง นักวิเคราะห์คาดการณ์ราคาขายห้องควรจะมีราคาประมาณเท่าใด **(คะแนน 2%)**

   <u>หมายเหตุ: จะเลือกใช้ตัวแปรต้นทั้งหมดหรือเลือกใช้ตัวแปรต้นตัวใดตัวหนึ่งก็ได้</u>

ตารางที่ 1 คลังข้อมูลอสังหาริมทรัพย์สำหรับตั้งราคาขายห้องชุด

ขนาดพื้นที่ใช้สอยในห้อง (Size of usable area)	ราคาประเมินจากกรมที่ดิน (Estimated Price by Dept. of Lands)	จำนวนห้องย่อย (Number of usable rooms)	ราคาขาย (Sell price)
ข้อมูลฝึกฝน (Training set)			
96.0 sq.m.	900,000 Baht	2 rooms	1,200,000 Baht
118.0 sq.m.	1,250,000 Baht	2 rooms	1,900,000 Baht
141.2 sq.m.	1,500,000 Baht	3 rooms	3,000,000 Baht
129.6 sq.m.	1,450,000 Baht	3 rooms	2,800,000 Baht
110.0 sq.m.	1,150,000 Baht	2 rooms	1,600,000 Baht
105.0 sq.m.	1,000,000 Baht	2 rooms	1,500,000 Baht
ข้อมูลทดสอบ (Testing set)			
125.0 sq.m.	1,300,000 Baht	3 rooms	???

*** การทดสอบข้อนี้อนุญาตให้ใช้ Scikit-learn library และ/หรือ PyTorch library ได้**

2. **เรื่อง: งานการจำแนกประเภท (Classification and regression tasks)**
   หน่วยงานประปาต้องการตั้งโรงบำบัดน้ำเพื่อจ่ายให้กับครัวเรือนและภาคอุตสาหกรรม ได้เลือกใช้งานเทคโนโลยีคำนวณเพื่อวิเคราะห์ข้อมูลเพื่อประเมินว่ามีความปลอดภัยหรือไม่ **(คะแนน 15%)**
   กำหนดให้

   - ระดับค่าอันตรายในแต่ละฟีเจอร์จากเครื่องมือวัด
     - aluminium - อันตรายหากเกินค่า 2.8
     - ammonia - อันตรายหากเกินค่า 32.5
     - arsenic - อันตรายหากเกินค่า 0.01
     - barium - อันตรายหากเกินค่า 2
     - cadmium - อันตรายหากเกินค่า 0.005
     - chloramine - อันตรายหากเกินค่า 4
     - chromium - อันตรายหากเกินค่า 0.1
     - copper - อันตรายหากเกินค่า 1.3
     - flouride - อันตรายหากเกินค่า 1.5
     - bacteria - อันตรายหากเกินค่า 0
     - viruses - อันตรายหากเกินค่า 0
     - lead - อันตรายหากเกินค่า 0.015
     - nitrates - อันตรายหากเกินค่า 10
     - nitrites - อันตรายหากเกินค่า 1
     - mercury - อันตรายหากเกินค่า 0.002
     - perchlorate - อันตรายหากเกินค่า 56
     - radium - อันตรายหากเกินค่า 5
     - selenium - อันตรายหากเกินค่า 0.5
     - silver - อันตรายหากเกินค่า 0.1
     - uranium - อันตรายหากเกินค่า 0.3
     - is_safe - class attribute {0 คือ น้ำยังปนเปื้อนมากเกินเกณฑ์ → Not safe,
       1 คือ น้ำผ่านการกรองปลอดภัยในระดับที่ยอมรับได้ → Safe}
   - ชุดข้อมูลและเกณฑ์อันตรายในแต่ละสสารที่เจือปนอยู่ตามข้อกำหนดของข้อมูลในแหล่งอ้างอิง: https://www.kaggle.com/datasets/mssmartypants/water-quality
   - ให้แบ่งข้อมูลด้วยใช้การ test size = ***20%*** และ random state สำหรับการสุ่มตัวอย่างที่ ***42*** **เท่านั้น**

จงหา

1.) ควรใช้โมเดลจำแนกแบบใดที่ได้ F1-score สูงที่สุดเพื่อใช้ในเชิงปฏิบัติการ โดยพิจารณาตัวแปรต้นวิเคราะห์ 19 สารปนเปื้อน เพื่อทำนายว่าน้ำที่ตรวจสอบนั้นปลอดภัยต่อการจ่ายให้ภาคครัวเรือนหรือไม่ **(คะแนน 7%)**

2.) สมมติว่าน้ำที่ทำการกรองและผลิตออกมานั้นวัดค่าด้วยเครื่องมือวัดและได้ปริมาณสารปนเปื้อนดังข้างใต้ น้ำที่ผลิตได้นั้นปลอดภัยหรือไม่ จงใช้โมเดลที่เรียนรู้มาเป็นตัวทำนาย **(คะแนน 2%)**

   ➢ mercury = 0.01 และ uranium = 0.01 (ค่าอื่น ๆ วัดได้ที่ 0)

```
import kagglehub
import os

# Download latest version
dataset_dir = kagglehub.dataset_download("mssmartypants/water-quality")
print("Path to dataset files:", dataset_dir)

# Find the CSV file within the downloaded directory
for filename in os.listdir(dataset_dir):
  if filename.endswith(".csv"):
    filepath = os.path.join(dataset_dir, filename)
    break

####################################
# Load the dataset into a DataFrame …
# Data wrangling and pre-processing …
# Interacting features (Optional)…
# Split the data …
*** test_size=0.2, random_state=42 for training/testing set only!!! ***


########################################
# In case of using ML model
# Model initialization …
# Model fitting …
# Evaluation metrics …
# Prediction …
```

3.) จากข้อมูลราคาที่ดินและราคาขายห้องชุดในข้อ 1. ใหญ่ มีข้อมูลเพิ่มเติมด้านการวัดและประเมินโดยกรมควบคุมมลพิษ ด้วยเหตุนี้จึงมีการกำหนดราคาขายใหม่ของห้องชุด ซึ่งราคาขายใหม่ของห้องจากข้อ 1.2) ควรจะมีราคาเท่าไหร่ และควรมีราคาที่สูงกว่า น้อยกว่า หรือคงเดิมเมื่อเทียบกับราคาประเมินก่อนหน้า กำหนดให้ข้อมูลการประเมินราคาขายใหม่ที่ประเมินจากข้อมูลอสังหาริมทรัพย์เป็นไปตามตารางที่ 2 ข้างใต้ **(คะแนน 6%)**

ตารางที่ 2 ตารางข้อมูลอสังหาริมทรัพย์สำหรับตั้งราคาขายห้องชุดใหม่ซึ่งใช้ข้อมูลประเมินเพิ่มเติมจากกรมควบคุมมลพิษประกอบการพิจารณา

ขนาดพื้นที่ใช้สอยในห้อง Unit: sq.m.	ราคาประเมินจากกรมที่ดิน Unit: Million-Baht	จำนวนห้องย่อย Unit: Rooms	การวัดค่าและประเมินจากกรมควบคุมมลพิษ																			ราคาขายใหม่ Unit: Million-Baht
			aluminium	ammonia	arsenic	barium	cadmium	chloramine	copper	flouride	bacteria	viruses	lead	nitrates	nitrites	mercury	perchlorate	radium	selenium	silver	uranium	Is_safe	
ข้อมูลฝึกฝน (Training set)																						
96.0	0.90	2	1.0	9.1	0.0	0.1	0.0	1.0	0.0	1.2	0.0	0.0	0.1	2.0	1.0	0.0	22.3	2.2	0.05	0.2	0.0	0	1.1
118.0	1.25	2	0.2	7.7	0.0	0.5	0.0	1.2	0.5	0.9	0.0	0.0	0.0	1.5	0.1	0.0	19.1	1.1	0.1	0.02	0.0	1	2.0
141.2	1.50	3	0.1	5.1	0.0	0.1	0.0	0.5	0.2	0.5	0.1	0.1	0.0	5.5	0.2	0.0	11.5	0.5	0.1	0.05	0.0	0	2.9
129.6	1.45	3	0.2	5.3	0.0	0.2	0.0	1.5	0.4	0.6	0.0	0.0	0.0	3.4	0.3	0.0	8.8	1.2	0.09	0.03	0.0	1	2.9
110.0	1.15	2	0.0	1.2	0.0	0.1	0.0	0.9	0.1	0.4	0.0	0.0	0.0	1.0	0.1	0.0	7.1	0.8	0.1	0.03	0.0	1	1.7
105.0	1.00	2	3.0	10.1	0.1	0.6	0.0	2.0	0.0	1.1	0.0	0.0	0.0	2.1	1.0	0.0	12.9	3.0	0.15	0.04	0.01	0	1.5
ข้อมูลทดสอบ (Testing set)																							
125.0	1.30	3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.01	0.0	0.0	0.0	0.0	0.01	???	???

Dataframe ที่เพิ่มเข้ามาในส่วนข้อมูลตารางที่ 2 ข้างต้น

```
columns = [
   "size", "price", "rooms",
   "aluminium", "ammonia", "arsenic", "barium",
   "cadmium", "chlorine", "copper", "fluoride",
   "bacteria", "viruses", "lead", "nitrates",
   "nitrites", "mercury", "perchlorate", "radium",
   "selenium", "silver", "uranium", "is_safe",
   "new_price"
]

# Training set
training_data = [
   [96.0,  0.90, 2, 1.0, 9.1, 0.0, 0.1, 0.0, 1.0, 0.0, 1.2, 0.0, 0.0, 0.1, 0.0, 2.0, 1.0, 0.0, 22.3, 2.2, 0.05, 0.2, 0, 1.1],
   [118.0, 1.25, 2, 0.2, 7.7, 0.0, 0.5, 0.0, 1.2, 0.5, 0.9, 0.0, 0.0, 0.0, 0.0, 1.5, 0.1, 0.0, 19.1, 1.1, 0.1, 0.02, 1, 2.0],
   [141.2, 1.50, 3, 0.1, 5.1, 0.0, 0.1, 0.0, 0.5, 0.2, 0.5, 0.1, 0.1, 0.0, 0.5, 5.5, 0.2, 0.0, 11.5, 0.5, 0.1, 0.05, 0, 2.9],
   [129.6, 1.45, 3, 0.2, 5.3, 0.0, 0.2, 0.0, 1.5, 0.4, 0.6, 0.0, 0.0, 0.0, 3.4, 0.3, 0.0, 0.0, 8.8, 1.2, 0.09, 0.03, 1, 2.9],
   [110.0, 1.15, 2, 0.0, 1.2, 0.0, 0.1, 0.0, 0.9, 0.1, 0.4, 0.0, 0.0, 0.0, 1.0, 0.1, 0.0, 0.0, 7.1, 0.8, 0.1, 0.03, 1, 1.7],
   [105.0, 1.00, 2, 3.0, 10.1, 0.1, 0.6, 0.0, 2.0, 0.0, 1.1, 0.0, 0.0, 0.0, 2.0, 2.1, 1.0, 0.0, 12.9, 3.0, 0.15, 0.04, 0, 1.5],
]

# Testing set
testing_data = [
   [125.0, 1.30, 3, 0.0, 0.0, 0.0, 0.0, 0.0,
    0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0,
    0.0, 0.01, 0.0, 0.0, 0.0, 0.01, None, None]
]
```